

최종 수행보고서

1. 연구동기

김초엽, 『관내분실』, 허블, 2018. 예는 죽은 사람들의 기억을 보관하여, 이들을 만나는 것 같은 효과를 주는 '도서관'이 등장한다. 소설 속의 '도서관'처럼, 현실에서 쉽게 만날 수 없는 인물을 실제로 만나는 것과 같은 인상을 주는 가상환경을 만들고 싶다는 생각에서 본 연구를 시작하였다.

특정 인물의 발화, 저서 등을 분석하여 그들의 '페르소나'를 그대로 표현하는 대화형 AI(이하 챗봇) 개발을 목표로 연구를 진행하였다. 이는 『관내분실』 속의 마인드 업로딩(사람의 정신을 컴퓨터와 같은 인공물에 전송하는 소설 속의 기술)과도 비슷한 맥락이라고 볼 수 있다.

본 연구는 학부생 수준에 맞춰, 가상 인물의 대화를 단순히 모방하는 대화형 AI 개발로 주제를 단순화하여 진행하였다.

2. 연구목표

"가상의 인물 혹은 특정 인물을 모방해서 문장을 생성하는 대화형 AI 개발"이라는 연구 목표 아래 다음과 같은 세부 단계별 목표를 두고 진행했다.

- 1) 기존 대화형 AI의 구조와 작동원리 분석
- 2) persona를 기반으로 한 generation chat-chat model 구조 설계
- 3) personalized dataset을 이용하여 출력 문장의 consistency 증가

3. 연구내용

가. 연구 방향 설정(모델 설정)

일반적인 대화형 모델에 이용되는 Question-Answering 기법은 크게 2가지로 분류할 수 있다.

1) Retrieval-based model(검색기반 모델)

Retrieval-based model은 질문에 대한 답을 미리 만들어 두고 답하게 하는 모델이다.

가) Method

필요한 QA 쌍 dataset을 준비한 후 데이터에 포함되지 않은 동일한 의도의 question에 대해서 적절한 답변을 낼 수 있도록 질문을 유사하게 복제하여 모델에 학습시킨다.

나) Advantage

준비된 dataset의 답변을 classify하는 구조이기에 답변의 내용이 정확하다.

다) Disadvantage

미리 준비된 QA dataset에서 응답하기에 포함되지 않은 주제에 대해서는 답변하지 못한다.

2) Generative model(생성기반 모델)

Generative model은 질문에 대한 답을 챗봇이 자동으로 생성하는 모델이다.

가) Method

실제 대화 데이터 (Text Corpus) QA 쌍을 일괄적으로 모델에 학습 시켜 새로운 답변을 유기적으로 조합 및 생성하여 답변하게 한다.

나) Advantage

커버할 수 있는 대화의 범위가 넓고 탄력성 있는 답변을 얻을 수 있다.

다) Disadvantage

적절한 문장을 생성하기까지 많은 dataset을 필요로 하고 검색기반 모델보다 문장의 완성도가 떨어진다.

위의 두 가지 모델에는 장단점이 존재한다. 특정 인물을 모방해야 하는 우리의 연구 주제에서는 이미 정해진 답변을 선택하는 Retrieval-model보다는 Generative model을 이용하는 것이 더 적합하고 학술적인 의미가 더 크다고 생각하여 Generative model의 대화형 AI를 기반으로 챗봇을 구현했다.

나. 연구 동향 분석

자연어 처리 분야의 연구 동향을 살핀 후, 각종 모델에 관한 공부를 논문 리뷰형식으로 진행하였다. 아래는 그중 몇 가지 모델들에 대한 설명이다.

1) SEQ2SEQ (RNN, GRU)

입력 문장을 받아 출력문장을 생성하는 QA task를 진행하기 위해서는 자연어를 수치화하여 연산하는 과정이 필요하다. RNN Encoder-decoder model은 텍스트와 같은 시계열 데이터를 처리하는데 뛰어난 성능을 보이는 구조의 모델이다. Encoder-decoder model은 아래 그림과 같이 두 개의 RNN cell로 구성되어있다.

첫 번째 RNN은 encoder로 가변 길이의 문장을 단어 단위로 쪼개어 고정 길이의 벡터로 mapping하고, encoder가 input seq x를 순차적으로 읽는 것에 따라 내부의 hidden state가 update 되고 문장의 마지막 심볼인 EOS token을 읽고 나면 vector c가 hidden state에 형성된다. 두 번째 RNN은 decoder로 인코딩된 벡터를 하나의 단어(형태소)로 디코딩하여 다시 하나의 문장으로 합치게 된다. decoder는 주어진 hidden state에서 다음 토큰을 생성하도록 train 된다.





Figure 1: An illustration of the proposed RNN Encoder-Decoder.

[그림 1] RNN Encoder-Decoder model

SEQ2SEQ는 RNN encoder-decoder model의 정형화된 구조 중 하나이며, 한 시계열 데이터를 다른 시계열 데이터로 변환하는 task(machine translation, question-answering, chatbot, image captioning, etc)에 이용되는 모델이다. 주로 LSTM이나 GRU 등의 RNN cell을 encoder와 decoder로 사용하고, 본 연구에 사용되는 모델은 GRU RNN cell로 구성되었다.

encoder의 마지막 GRU layer hidden state에는 고정길이 벡터로 input sequence의 정보가 응축되어있으며 이를 encoding이라고 부른다. decoder에서는 train dataset의 두 번째 시계열 데이터의 토큰이 각 RNN cell에서 지도하는 역할을 하여 학습이 진행되며 이를 통해 충분한 학습이 진행된다면 적합한 답변을 생성하게 parameter가 조정된다.

GRU는 gated recurrent units의 약어로 게이트 메커니즘이 적용된 RNN 프레임워크의 일종이다. LSTM에서 영감을 받은 보다 간략한 구조로 되어 있고 reset gate, update gate만을 이용하여 계산이 이루어진다. LSTM과 구조상 큰 차이가 없고, 분석 결과도 큰 차이가 없다. 따라서 학습할 가중치가 적은 이점을 가진 GRU cell로 본 모델을 구성하게 되었다.




[그림 2] LSTM과 GRU 구조도

2) BERT

BERT는 대용량 unlabeled data로 language model pretraining을 진행한 후, 특정 task를 위한 labeled data로 transfer learning을 하는 방식의 모델이다.

BERT 이전에도 이와 유사한 구조를 가지는 ELMo, OpenAI GPT 등의 모델이 소개된 바 있다. BERT는 새로운 방식의 pre-trained language representation을 통해 모든 레이어에서 양방향성을 가지게 함으로써, 이전 모델들보다 성능이 더욱 향상되었다.



[그림 3] BERT, OpenAIGPT, ELMo의 차이점

BERT의 pre-trained language representation 방법은 Masked language model, Next sentence prediction 2가지이다.

가) Masked language model(MLM)

input 문장에서 랜덤하게 몇 개의 단어를 mask하고, 전체 문장을 transformer encoder에 입력한다. transformer encoder는 mask 된 단어를 예측하면서 학습을 진행한다. mask 된 단어를 예측할 때 mask 이전 단어만이 아닌 mask 앞뒤의 문장 전체를 활용하여, BERT 모델이 양방향성을 가질 수 있게 된다.

MLM 대신 Left-to-Right를 사용하면 성능 하락이 있고, 여기에 BiLSTM을 덧붙이더라도 MLM으로 학습을 진행할 때에 비해 낮은 성능을 보였다. 즉, MLM이 LTR이나 BiLSTM에 비해 Deep Bidirectional하고, 이러한 특징이 BERT의 성능을 높이는 데에 크게 기여했음을 알 수 있다.

나) Next sentence prediction

입력된 두 문장이 이어지는 문장인지 아닌지를 예측하면서 학습을 진행한다.

NSP를 학습하지 않을 경우 Natural Language Inference 계열의 task에서 큰 성능 하락을 보인다. 즉, 이 과정은 두 문장 사이의 관계를 이해하는 데에 도움을 주고 있음을 알 수 있다.

이외에도 기존의 모델이 사용하던 BookCorpus(800M words)에 Wikipedia의 2,500M 개의 words를 더하여 학습을 진행하였고, [SEP], [CLS] token을 pre-training 시에도 사용하는 등의 차이를 두었다. 이러한 차이점 덕분에 BERT는 기존 모델들보다 훨씬 좋은 성능을 보인다. BERT는 모델이 클수록 더 높은 성능을 보이며, 대부분의 NLP task에서 SOTA를 달


성하였다.

3) GPT2

앞서 설명한 바와 같이, NLP task를 수행할 때에는 일반적으로 task specific dataset으로 supervised learning을 하는 과정이 필요하다. GPT2는 이런 과정 없이, language model만으로 광범위한 작업을 수행하도록 한 모델이다. 이를 위해 GPT2는 zero-shot setting을 도입하였다.

모델은 기존 GPT 모델의 틀을 그대로 사용하였는데, normalization 레이어의 이동이나, batch size를 키우는 등의 작은 수정이 있었다.

GPT2는 자체 제작한 WebText(45M개 링크의 웹페이지 데이터)로 language model을 학습시켰으며, 가장 큰 모델은 15억 개의 parameter를 가지는 등 규모가 크다.



[그림 4] GPT2의 loss graph

language model의 parameter가 늘어날수록 train과 test의 perplexity가 떨어지는 것으로 보아, GPT2 또한 여전히 WebText에 대해 underfitting 상태임을 알 수 있다. 그림에도 8개 task 중 7개에서 SOTA를 달성하는 성능을 보였다.

다. 모델 구현

모델 조사 후, 자연어와 같은 시계열 데이터의 mapping이 직관적이고 비교적 단순한 구조인 Seq2Seq model부터 구현했다. 해당 코드는 <부록 1>에 첨부하였다.

model specification:

- RNN cell - GRU(gated recurrent unit)
- tokenizer = Okt (from konlpy)
- hidden layer : 256param
- activate function : ReLU
- apply teacher forcing

no segmentation for decoder (softmax)

prototype model을 완성한 후 구조 재설계하기 전 dataset과 performance의 연관성을 알아보기 위하여 [실험 1]을 진행하였다.

1) [실험 1] Train SEQ2SEQ with Genre dataset

가) Idea

한 인물의 일관성 있는 말투를 담은 대화 dataset을 구하여 각각 학습시킨 후 출력문장의 변화를 관찰한다.

나) Problem

SEQ2SEQ는 좋은 결과를 출력하기까지 상당히 많은 data의 양을 요구한다. 한 인물의 일관성 있는 대량의 대화 dataset을 구하기 쉽지 않다. 일반적인 대화 dataset의 양도 많지 않을뿐더러, 한 인물의 충분한 대화 dataset을 모을 수 있다는 것도 보장되어 있지 않다. 충분한 대화가 존재한다 해도 dataset을 정리하기가 난해해 상당한 시간이 소요될 것으로 보인다. 또한 직접 수기로 제작하기에도 한계가 존재한다.

따라서 한 인물이 아닌 비슷한 특성의 character들을 클러스터링하여 대화 dataset을 모으는 것으로 목표를 수정했고 다음과 같은 방법으로 data를 수집하였다.

- ① characteristic이 가장 상이라고 여겨지는 사극 / 하이틴 장르 선정
- ② 드라마 대본 text를 크롤링하여 극 중 인물의 대화 쌍 dataset 수집
- ③ 사극의 경우 인물 전부를, 하이틴의 경우 학생들의 발화만 선택적으로 전처리
(사극 : 62,039pair / 하이틴 : 22,821pair)

고우! 가요 가!
기봉샘은요? 어어... 좀... 편찮으시대서. 웨리! 스파트!
프린트 안 주셨는데.. 어머... 짜리?
으... 후... 준비... 시작.
한수정샘... 깜짝야!
그만 두셨어요? ... 어?
그만 두셨어요? 예?! 무섭잖아아!
이사장님... 보이지.
예? 잔주름. 하룻밤 새 0.5밀리 늘어났어. 한수정샘 땀에. 이렇게 내속을 썩일 수가 있는 거예요?
죄송합니다. 사람이 어쩔 이렇게 무책임할 수가 있어요? 어려운 일이 생겨도 끝까지 버티는 게 프로 정신 아니예요?
이사장님이 그런 말씀 하실 입장 아니지 않나요? 뭐예요?

[그림 5] 하이틴 드라마 dataset 예시

마음 먹은게냐? ...아직 모르겠습니다...

...그래. 너도 마음이 복잡하겠지...하지만 원수하고 한 하늘 이고 마음 편히 잘 수나 있겠냐? ...의자왕자님을 불러주십시오...

정말 잘 생각했다. 잘 생각했어.무진장군도 기뻐하실 것이다.염려마라. 복수는 내가 할테니... 꼭 그리 해주십시오.

그럼, 앞으로 어찌 살지 계획이 섰느냐?내가 무얼 해주면 되겠느냐? 아버지의 소원처럼 속세를 떠날 것입니다

얼마나 떠나 있을 것이냐? 안 돌아올 것입니다.

그럼 이게 마지막이라는 것이냐... ..섭섭하구나... ..절 아직도 아우라 여깁니까?

물론이다. 난 태어나기 전부터 내 아우였고... 지금도, 앞으로도 나의 아우다. 무슨 일이 있어도 말입니까?

무슨 일이 있어도... 제가 왕자님을 많이 오해했던 것 같습니다...오늘밤 이 아우와 함께 주무시겠습니까?..?

좋지. 내가 청하고 싶은 말이다. 여긴 너무 누추합니다.

그럼 저녁에 보도록 하자. 알겠습니다.

대도를 왜 왕자님이 들고 가시는 게냐?설마 왕자님 말씀대로 복수 따윈... 아저씨...배고파요, 밥 좀 주세요.

기억나느냐? 어찌 잊겠습니까...

[그림 6] 사극 드라마 dataset 예시

다) Method

(1) dataset을 분리하여 각각 학습

사극과 하이틴 드라마 대화 쌍을 각각의 SEQ2SEQ model에 학습하여 결과를 도출한다. 이 경우 각각의 모델은 다른 model parameter를 가지고 독립적으로 출력문장을 계산한다. 같은 문장을 input으로 하는 test data를 이용하여 장르별 캐릭터의 특성이 문장에 잘 녹아 있는지 확인한다.

(2) zero shot : trained by first token of input ([hist], [high])

사극과 하이틴 드라마 dataset을 모두 합친 후 Question의 맨 앞에 dataset의 종류별로 labeling 한다. 이 경우 label이 encoder에 들어가는 첫 번째 토큰으로 작동하며, 한 개의 모델이 모든 dataset을 학습하여 통합적으로 출력문장을 계산한다. 학습이 끝난 모델에서 같은 문장이면서 앞의 label만 다른 test data로 말투가 다른 문장을 잘 생성하는지 확인할 수 있다.

<high> ...결과는 언제 나와요? <hist> 예...대감. <high> ...난 도, 이번만 날이나? 때마다 떨어지는게 별동별이야. 내년에 또... <high> 소문이 꼭 퍼졌던데요... 결혼 축하합니다, 선생님. <high> 혹시 너 일부러 이러는 거냐? 만약 사실이라면 명절치러 될 거야. <hist> 예 떠난지 사흘째 되오니 거의 도착하고 있을 것입니다 <hist> 나는 회임을 하기는 틀린 몸이네 태기가 있으려면 뱀배 있었지 <hist> 당연한 것 아니냐? <hist> 입을 다물고 있지 못하겠느냐 <hist> 멋대로 전역을 주살한 일도 죄가 되지 않는다? <high> 어? 형이다.. <hist> 일국의 폐하답지 않으신 말씀이십니다 백성들을 생각 하시오소서 <hist> 군국기무처의 총재를 맡아주시지요 <hist> 이제 다..우리 왕자대마 닥이지요 <hist> 뉘시오 <high> 하..	<high> 글쎄...한 일주일쯤 걸릴거 같은데요. <hist> 하오나 마마! 그것은 너무... <high> 나 그걸두 아파한데 사과할려구 했었던 말야. <high> ... <high> 상관없는데요. <hist> 너는 이번 일을 어찌 생각하느냐 나는 좀지 않은 과거와 지푸 되 <hist> 무슨 말씀이시옵니까 마마 지난 해 봄에 회임을 하셔야 만조백관의 하례를 받으셨지 <hist> 그렇지요.만일 비 전하가 폐하의 음종을 위임하지 않았다면..선제폐하의 진노로 결코 살아남지 못했을 겁니다.. <hist> 소인들은 역을하옵니다 <hist> 거열성으로 사람을 놓아 자세히 알아본 바그 동원 전역의 행포에 시달려온 백성들의 원성이 차차했습니다. <high> 깜짝이야. 처리시켜 <hist> 아마 나는 모르오 내가 아는 것은 오직 숙부 나의 지아비 나의 부군뿐이오 <hist> 글썄옵시다 <hist> 보시겠습니까? <hist> 여기가 수월유수 대령댁이었단 <high> 그래 마빠. 참여요...
---	---

[그림 7] zero-shot 드라마 dataset 예시

위와 같은 조건과 dataset으로 모델을 학습시켰다. (***)결과는 5번 항목에 첨부)

하지만 드라마 대본에서 크롤링 후 추가적인 정제를 하지 않은 날것의 데이터를 이용하였고, 일반적인 타 모델의 데이터 학습량에 비해 적은 양이었으므로 출력 결과의 품질이 좋지 않았다.

예상한 성능보다 훨씬 뒤쳐졌기 때문에 추가적인 구조 설계를 진행하고 학습방법에 대한 대안을 찾아보기로 하였다.

2) [실험2] Train accent with GPT2-SEQ2SEQ concat model (Full sentence)

가) idea

대화 쌍 생성에 좋은 성능을 보이는 pretrain된 GPT2모델을 이용, SEQ2SEQ network의 역할을 말투 변경을 위한 모듈로 국소적으로 제한을 둬, GPT에 11000여 쌍의 chatbot dataset을 이용하여 Fine tuning을 진행한 후 SEQ2SEQ network에 concat하여 구조 설계.

input seq → GPT2 → intermediate output seq → SEQ2SEQ → final output set

나) Method

말투변경을 위한 데이터셋 직접 제작 : 11823pairs * 3 => total 55469pairs

위로해 드립니다.	위로해 드립니다.
여행은 언제나 좋죠.	여행은 언제나 좋습니다.
여행은 언제나 좋죠.	여행은 언제나 좋습니다.
눈살이 찌푸려지죠.	눈살이 찌푸려집니다.
다시 새로 사는 게 마음 편해요.	다시 새로 사는 게 마음 편합니다.
다시 새로 사는 게 마음 편해요.	다시 새로 사는 게 마음 편합니다.
잘 모르고 있을 수도 있어요.	잘 모르고 있을 수도 있습니다.
시간을 정하고 해보세요.	시간을 정하고 해보십시오.
시간을 정하고 해보세요.	시간을 정하고 해보십시오.
자랑하는 자리니까요.	자랑하는 자리여서 그렇습니다.
그 사람도 그럴 거예요.	그 사람도 그럴 것입니다.
그 사람도 그럴 거예요.	그 사람도 그럴 것입니다.

[그림 8] 다나까체 dataset 예시

위로해 드립니다.	위로해 드림.
여행은 언제나 좋죠.	여행은 언제나 좋음.
여행은 언제나 좋죠.	여행은 언제나 좋음.
눈살이 찌푸려지죠.	눈살이 찌푸려짐.
다시 새로 사는 게 마음 편해요.	다시 새로 사는 게 마음 편함.
다시 새로 사는 게 마음 편해요.	다시 새로 사는 게 마음 편함.
잘 모르고 있을 수도 있어요.	잘 모르고 있을 수도 있음.
시간을 정하고 해보세요.	시간을 정하고 해보셈.
시간을 정하고 해보세요.	시간을 정하고 해보셈.
자랑하는 자리니까요.	자랑하는 자리잖슴.
그 사람도 그럴 거예요.	그 사람도 그럴 거임.
그 사람도 그럴 거예요.	그 사람도 그럴 거임.

[그림9] 음슴체 dataset 예시

위로해 드립니다.	위로해 드리오.
여행은 언제나 좋죠.	여행은 언제나 좋소.
여행은 언제나 좋죠.	여행은 언제나 좋소.
눈살이 찌푸려지죠.	눈살이 찌푸려지오.
다시 새로 사는 게 마음 편해요.	다시 새로 사는 게 마음 편하오.
다시 새로 사는 게 마음 편해요.	다시 새로 사는 게 마음 편하오.
잘 모르고 있을 수도 있어요.	잘 모르고 있을 수도 있소.
시간을 정하고 해보세요.	시간을 정하고 해보시오.
시간을 정하고 해보세요.	시간을 정하고 해보시오.
자랑하는 자리니까요.	자랑하는 자리니까 그런것이오.
그 사람도 그럴 거예요.	그 사람도 그럴 것이오.
그 사람도 그럴 거예요.	그 사람도 그럴 것이오.

[그림 10] 하오체 dataset 예시

위와 같은 조건과 데이터셋으로 모델을 학습시켰다.

3) [실험 3] Train accent with GPT2-SEQ2SEQ concat model (suffix)

가) idea

실험 2에서 dataset의 말투를 바꾸는 과정에서 문장의 끝부분에서 한 어절, 많아도 두 어절의 어미 부분에서만 변화가 있는 것을 토대로 seq2seq에 마지막 어절만 학습시키는 형태로 문장 생성

나) Method

실험 2와 거의 동일하다. 하지만 마지막 어절만 분리하여 SEQ2SEQ에 학습을 진행하였고 나머지 조건은 동일하다.

가네요.	감
드립니다.	드림
종조.	종음
종조.	종음
찌푸려지죠.	찌푸려짐
편해요.	편함
편해요.	편함
있어요.	있음
해보세요.	해보셈
해보세요.	해보셈
자리니까요.	자리여서 그럼
거예요.	거임
거예요.	거임
즐기세요.	즐기셈

[그림 11] 실험 3 dataset 예시(음슴체)

4) [실험 4] Train accent with GPT2-SEQ2SEQ concat model (verb)

가) Idea

말투는 동사나 형용사에 붙는 접미어에 의존하는 경향이 있다. 따라서 대부분의 명사는 인물의 말투에 큰 영향을 미치지 않는다. 또한 실험 3의 경우 마지막 어절에서만 문체가 변화하지 않는 경우가 존재하기에 이를 해결하기 위하여 konlpy tokenizer에서 제공하는 형태소 분석기를 이용하여 명사를 제외한 토큰들을 SEQ2SEQ에 학습하는 형태로 실험을 진행하기로 하였다. 나머지 조건은 동일하다.

4. 연구 결과


구체적인 실험 결과는 [부록2]에 첨부하였다.

가. [실험 1] Train SEQ2SEQ with Genre dataset


구체적인 실험 결과는 [부록2]에 첨부하였다.

나. [실험 2] Train accent with GPT2-SEQ2SEQ concat model (Full sentence)


구체적인 실험 결과 text는 [부록3]에 첨부하였다. train 과정 중의 loss graph는 다음과 같다. (xlabel : trained seq pair, ylabel : loss)



[그래프 1] 실험 2 다나까체 total loss graph




[그래프 2] 실험 2 음슴체 total loss graph




[그래프 3] 실험 2 하오체 total loss graph

다. Train accent with GPT2-SEQ2SEQ concat model (suffix)


구체적인 실험 결과 text는 [부록4] 에 첨부하였다. train 과정 중의 loss graph는 다음과 같다. (xlabel : trained seq pair, ylabel : loss)



[그래프 4] 실험 3 다나까체 total loss graph




[그래프 5] 실험 3 음습체 total loss graph



[그래프 6] 실험 3 하오체 total loss graph

라. Train accent with GPT2-SEQ2SEQ concat model (verb)

구체적인 실험 결과 text는 [부록5] 에 첨부하였다. train 과정 중의 loss graph는 다음과 같다. (xlabel : trained seq pair, ylabel : loss)




[그래프 7] 실험 4 total loss graph

5. 논의

가. 실험 1 결과 분석

실험 결과에서 알 수 있듯이 좋지 않은 수준의 문장 생성능력을 보여주었다. overfitting이 일어날 정도(epoch 수 100)까지 학습을 진행하였음에도 불구하고 좋은 성능을 보이지 못했다.

드라마 대본에서 추가적인 정제를 하지 않은 날것의 데이터를 이용하였기에 dataset의 품질 문제라고 생각하였고, dataset을 관찰한 결과 다음과 같은 사실을 알 수 있었다.




(a) RNNenc without segmentation

[그림 12] segmentation 미적용 시 RNN의 BLEU graph

segmentation이 적용되지 않은 RNN은 문장의 길이가 길어질수록 심각한 성능 저하를 보인다. 따라서 문장의 길이가 대체로 긴 경향을 보이는 드라마 dataset의 이용과, 광범위한 mapping에 비해 너무나 적은 dataset에 의해 결과가 좋지 않았던 것으로 보인다.

나. 실험 2, 3, 4 결과 분석

1) Epoch 수에 따른 loss, BLEU 등의 지표 & dataset의 specification/type 분석



[그래프 8] 실험2,3,4의 BLEU graph

*실선, 파선, 점선 -> 실험2, 실험3, 실험4

**red, magenta, blue -> 다나까체, 음습체, 하오체

Full seq의 경우에는 모든 dataset에 대해 다섯 번째 에폭에서 모델의 성능이 저하되었고, 심지어 다나까체의 경우는 학습이 더 진행되었을 때 계속 같은 단어(token)를 반복하여 출력하는 경우가 상당한 빈도로 관찰되었다. 이것은 RNN cell에서 흔히 발생하는 gradient exploding problem이고 GRU cell과 skip connection, dropout을 모두 적용한 본 모델에서 이 문제가 발생한 것으로 보아, vocabulary 문제로 예측된다.


예측해야 할 단어의 범주가 너무 광활하기에 Softmax의 확률을 계산할 때 과부하가 걸리는 경우 일 것으로 보이고 이를 해결하기 위해서는 일부 단어만 뽑아 확률을 구하고 여기서 구하는 loss만큼만 parameter를 업데이트하는 방법인 Candidate sampling을 이용하여 개선할 수 있을 것이다.

6. 결론 및 발전 방향

가. 추후 연구

앞서 연구 동기에서 설명했듯이 말투뿐만 아니라 특정 인물의 정보를 담고 있는 일관성 있는 문장을 생성 모델을 최종적인 목표로 삼고 있다. 이 문제를 해결하기 위해서 가장 먼저 해야 할 일은 character information의 저장과 적용 방법을 고안하는 것이다. 현재의 연구 방향은 획기적인 구조설계나, 창의적인 기법적용 같은 것이 아닌, dataset에 의존적이다. 따라서 소량의 인물 정보를 입력했을 때 그것을 문장 생성에 자연스럽게 녹여낼 수 있는 구조적 설계 방법을 모색해보는 것도 좋을 것 같다. (ex> 24세, 학생 -> 나이와 직업에 대한 질문에 대한 답변 생성할 수 있게)

또한 단기간의 관점에서 보자면 실험 3, 4를 토대로 어미만을 학습했을 때 적은 dataset으로 효율적으로 문장을 생성하는 것을 확인할 수 있다. 따라서 시계열 dataset을 다루는 RNN보다는 CNN이나 다른 효율적인 네트워크 구조로 대체가 가능할 것이고 더 좋은 성능을 보일 것으로 기대된다.



[그래프 9] 실험 2 다나까채 10epoch, lr=0.005 total loss graph

```
먼저 생활패턴을 살펴 보세요. 볼 수 있을 겁니다. BLEU = 0.23076923076923078
친구들이 보고싶었나봐요. 방학 이 참 짧습니다. BLEU = 0.21428571428571425
주거적으로 해주는 게 좋죠. 을 받아 보십시오. BLEU = 0.14285714285714285
용서를 구하세요. 제 가 있는지 사과 하십시오. BLEU = 0.16666666666666669
계단 조심하세요. 운동 해보십시오. BLEU = 0.18181818181818182
마음에 들면 줘보세요. 연애 를 알 좋을 것 같습니다. BLEU = 0.10526315789473682
너무 낙담하지 마세요. 조심하십시오. BLEU = 0.3333333333333333
마음이 허전하신가봐요. 좋은 추억 이 될 겁니다. BLEU = 0.1875
나 자신에 집중하세요. 언제나 1순위에 자신을 두세요. 제 가 빠를수록 시작. BLEU = 0.21428571428571425
잠깐 핸드폰을 내려두세요. 진심 으로 물어보십시오. BLEU = 0.13333333333333333
기다리는 동안 많은 생각이 들었겠네요. 많이 힘들었겠습니다. BLEU = 0.6153846153846154
제가 있잖아요. 있으면 있으면 있으면 하십시오. BLEU = 0.15789473684210523
이야기를 하지 않고 결정했나봐요. 그래서 는 는 에 가보십시오. BLEU = 0.11111111111111119
자신의 잠재력을 믿어보세요. 기억 이 생각 생각 받아 스스로 에게 물어보십시오. 물어보십시오. BLEU = 0.10810810810810814
포커페이스를 유지해보세요. 눈 을 감고 대화 를 줘 보십시오. BLEU = 0.19047619047619047
감사합니다. 긍정 적 이든 관심 을 알아보십시오. BLEU = 0.04545454545454546
아이스크림 먹어보세요. 따뜻한 물 한 잔 드십시오. BLEU = 0.0588235294117647
잘했어요. 좋은 선택 하셨습니다. BLEU = 0.07142857142857141
막막하겠네요. 열심히 열심히 하십시오. BLEU = 0.13333333333333333
```

[그림 13] 실험 2 다나까채 10epoch, lr=0.005 blue 결과

또 Full seq에서 epoch을 늘릴 때마다 오히려 모델의 성능이 떨어지던 문제를 learning rate를 조절하면서 해결되는 모습이 보였다. 추후 추가적인 연구에서 parameter들을 미세 조정하는 방식으로 성능을 조금씩 높여낼 수 있을 것으로 보인다.

8. Reference

Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder–decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*.

Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). Empirical evaluation of gated recurrent neural networks on sequence modeling. *arXiv preprint arXiv:1412.3555*.

Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*.

Jean, S., Cho, K., Memisevic, R., & Bengio, Y. (2014). On using very large target vocabulary for neural machine translation. *arXiv preprint arXiv:1412.2007*.

Pouget-Abadie, J., Bahdanau, D., Van Merriënboer, B., Cho, K., & Bengio, Y. (2014). Overcoming the curse of sentence length for neural machine translation using automatic segmentation. *arXiv preprint arXiv:1409.1257*.

Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). Language models are unsupervised multitask learners. *OpenAI blog*, 1(8), 9.

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. In *Advances in neural information processing systems* (pp. 3104–3112).